

Évaluation Comparative de Modèles d'Apprentissage Automatique

Détection d'Intrusions Réseau : Modèles Tabulaires vs Graph Neural Networks

Cedric Tanekeu

Projet de Synthèse

Automne 2025

Plan de la présentation

- 1 Introduction & Contexte
- 2 Dataset & Méthodologie
- 3 Résultats : Modèles Tabulaires
- 4 Approches Graphes (GNN)
- 5 Comparaison & Analyse
- 6 Conclusion & Perspectives

Problématique

- Cyberattaques de plus en plus sophistiquées
- IDS traditionnels (signatures) limités
- Nécessité de détecter les nouvelles menaces

Défis

- Classes déséquilibrées (80% trafic normal)
- Attaques rares difficiles à détecter
- Généralisation sur nouvelles attaques

Notre Approche

Comparer deux paradigmes :

- 1 Modèles tabulaires classiques
- 2 **Graph Neural Networks (GNN)**

Question de recherche

Les GNN apportent-ils une amélioration significative par rapport aux modèles classiques ?

- 1 Établir des **références solides** avec modèles classiques sur CSE-CIC-IDS2018
- 2 Identifier les **limitations** des approches tabulaires
- 3 Construire un **graphe de similarité** (k-NN) entre flux réseau
- 4 Évaluer **4 architectures GNN** : GCN, GAT, GraphSAGE, GAE
- 5 Comparer de manière **objective** : mêmes données, mêmes métriques

Caractéristiques

- Dataset moderne (2018)
- Trafic réel capturé en environnement universitaire
- **3 millions de flux** pour notre étude
- 78-80 features (statistiques réseau)
- 10 classes retenues

Types d'attaques

- DDoS (HOIC, LOIC)
- DoS (Hulk, SlowHTTPTest, Slowloris, GoldenEye)
- Brute Force (FTP, SSH)
- Bot, Infiltration


Déséquilibre

- Train : 80% Benign
- Test : 72% Benign
- Classes rares : $< 0.1\%$

Challenge

Détecter les classes ultra-minoritaires tout en maintenant de bonnes performances globales

Pipeline de prétraitement



Étapes clés :

- Suppression colonnes : Timestamp, IP, Port (éviter target leakage)
- Gestion valeurs manquantes : 1.1M remplacées par médiane
- Suppression classes rares : moins de 100 échantillons
- Encodage labels : LabelEncoder (0-9)

Modèles linéaires

- Logistic Regression
- SGDClassifier
- LinearSVC
- Ridge Classifier

Ensembles (Bagging)

- Random Forest
- Extra Trees
- Bagging Classifier



Ensembles (Boosting)

- **XGBoost**
- LightGBM
- Gradient Boosting
- HistGradient Boosting
- AdaBoost

Autres

- Decision Tree
- k-NN
- Naive Bayes (Gaussian, Bernoulli)



Résultats : Performances



Observations clés :

- Modèles d'ensemble : meilleurs F1-scores (0.6-0.9)
- **Accuracy élevée mais trompeuse** (90-100%)

Résultats : Temps & Multi-métriques



Constat :

- HistGradientBoosting : très lent (45 min)
- Accuracy ~95-100% vs F1-score ~60-65%
- **Divergence révélatrice du déséquilibre**

Performances XGBoost

- Accuracy : **91.5%**
- F1-weighted : **87.4%**
- **F1-macro : 23.9%** ← Problème !
- **Balanced Accuracy : 33.3%**
- **MCC : ≈ 0**

Problème majeur

Biais vers la classe majoritaire "Benign"

- Excellentes performances sur attaques volumétriques (DDoS)
- Moyennes sur attaques lentes (Slowloris)
- **Nulles sur classes nouvelles (Bot, Infiltration)**

Construction du graphe k-NN

Motivation : Exploiter la **structure de similarité** entre flux réseau

Méthodologie

- 100,000 nœuds (flux réseau)
- 67 features par nœud
- k-NN avec $k=10$
- Distance euclidienne

Résultat

- 484,602 arêtes
- Degré moyen : 9.69
- 3,186 composantes
- Plus grande : 68,241 nœuds

Principe

Un flux similaire à des flux d'attaque a plus de chances d'être malveillant

Avantage

Les classes rares "empruntent" des informations de leurs voisins

- ① **GCN** (Graph Convolutional Network)
 - Agrège uniformément les voisins
 - Simple et efficace
- ② **GAT** (Graph Attention Network)
 - Mécanisme d'attention
 - Pondère dynamiquement les voisins
- ③ **GraphSAGE** (Sample and Aggregate)
 - Échantillonnage de voisins
 - **Apprentissage inductif**
 - Crucial pour flux temps-réel
- ④ **GAE** (Graph Auto-Encoder)
 - Apprentissage non supervisé
 - Reconstruction de structure

Mode transductif : Le modèle connaît la structure complète du graphe

Modèle	Accuracy	F1-macro	MCC
GraphSAGE	98.91%	90.27%	0.9659
GCN	98.75%	88.76%	–
GAT	94.83%	77.98%	–
XGBoost (réf.)	91.5%	23.9%	≈ 0

Performance exceptionnelle de GraphSAGE

+66.4 points de F1-macro par rapport à XGBoost !

Mode inductif : Généralisation sur flux **jamais vus**

Modèle	Accuracy	F1-macro	MCC
GraphSAGE	98.87%	79.85%	0.9649
GCN	98.77%	88.02%	–
GAT	95.01%	72.19%	–

Robustesse remarquable

Dégradation modérée : 90.27% → 79.85% (**10 points**)

Crucial pour IDS temps-réel où nouveaux flux apparaissent constamment

3 mécanismes clés :

① Propagation d'information

- Flux rares (3 exemples) connectés à flux similaires
- "Emprunt" de connaissances des voisins
- **Résultat : 100% détection DDOS LOIC-UDP**

② Lissage des représentations

- Features bruitées moyennées avec voisins k-NN
- Représentation plus robuste

③ Contexte relationnel

- Modèles tabulaires : chaque flux indépendant
- GNN : un flux suspect entouré d'autres flux suspects = plus probable d'être une attaque

XGBoost vs GraphSAGE : Le choc des titans

Métrique	XGBoost	GraphSAGE
Accuracy	91.5%	98.91% (+7.4)
F1-weighted	87.4%	98.87% (+11.4)
F1-macro	23.9%	90.27% (+66.4)
Balanced Acc.	33.3%	88.29% (+55)
MCC	≈ 0	0.9659

Différence spectaculaire

GraphSAGE résout le problème du **biais vers la classe majoritaire**

Classes ultra-minoritaires :

- DDOS LOIC-UDP (3 ex.) : **100%** détection
- Classes volumétriques : F1 ≈ 0.99 -1.00

Quand privilégier quelle approche ?

Modèles Tabulaires

Avantages

- Implémentation simple
- Rapides (sauf HistGB)
- Interprétables (SHAP)
- Bien connus des équipes

Utiliser quand :

- Attaques courantes
- Classes bien représentées
- Besoin d'explicabilité
- Ressources limitées

Graph Neural Networks

Avantages

- **Excellents sur classes rares**
- Généralisation inductif
- Exploitation structure
- MCC élevé

Utiliser quand :

- Classes rares critiques
- Nouvelles attaques
- Vision contextuelle
- Few-shot learning
- Ressources GPU disponibles

Méthodologiques

- Un seul dataset principal
- Sous-échantillonnage (3M)
- Graphe limité (100k nœuds)
- Ressources GPU limitées

Techniques

- Conflits dépendances Python
- Temps entraînement longs
- Construction graphe k-NN coûteuse

Contextuelles

- Environnement universitaire
- Focus DDoS/DoS
- Trafic chiffré non traité
- Graphe statique (non temporel)

GNN

- Interprétabilité limitée
- Scalabilité (millions nœuds)
- Sensibilité construction graphe

① Modèles tabulaires atteignent leurs limites

- Accuracy élevée mais **trompeuse**
- F1-macro faible révèle biais vers classe majoritaire
- Échouent sur classes rares et nouvelles attaques

② GNN apportent amélioration spectaculaire

- **GraphSAGE : +66 points de F1-macro**
- 100% détection classes ultra-minoritaires
- Robuste en mode inductif

③ Le graphe k-NN est la clé

- Capture similarité entre flux
- Propagation d'information
- Contexte relationnel

Court terme

- Graphes temporels (snapshots horaires)
- Graphes IP-IP (au lieu de k-NN)
- Architectures GNN avancées

Moyen terme

- Autres datasets (CIC-DDoS2019, Bot-IoT)
- Semi-supervisé / Few-shot learning
- Robustesse aux attaques adversariales

Long terme

- Federated Learning avec GNN
- Explicabilité GNN pour analystes SOC
- Système hybride temps-réel

Contributions scientifiques

- ➊ Pipeline reproductible pour CSE-CIC-IDS2018
- ➋ Première comparaison systématique tabulaire vs GNN
- ➌ Résultats quantitatifs clairs sur classes rares
- ➍ Analyse détaillée des cas d'usage

Impact pratique

Recommandation : Architecture hybride

- Modèles tabulaires : première ligne de défense
- GNN : scénarios critiques (classes rares, nouvelles attaques)

Merci de votre attention

Questions ?

Cedric Tanekeu
Projet de Synthèse – Automne 2025

Configuration GNN

- 2 couches
- Hidden dimension : 64
- Dropout : 0.5-0.6
- Optimiseur : Adam (lr=0.01)
- Early stopping : patience 30

Environnement

- Google Colab (CPU/GPU T4, 51 GO RAM)
- Python 3.12
- PyTorch 2.0.1, PyTorch Geometric
- Scikit-learn, XGBoost, LightGBM